

Relatório da Análise de Algoritmos de Recomendação para Filmes

Felipe do Amparo Lauria (líder)

André Luís Mendes Júnior

Bruna Fontes Castro

Enrico Panico Laguna

Instituto de Biociências, Letras e Ciências Exatas, Unesp -
Universidade Estadual Paulista, 15054-000, São José do Rio
Preto - SP,
Brazil.

April 2024

1 Introdução

Há um grande consumo de conteúdos audiovisuais atualmente e isso foi impulsionado principalmente pelo crescimento das plataformas de streaming. O avanço da tecnologia e surgimento desse serviço o consolidou como principal forma de acesso a filmes, séries e documentários, substituindo, em grande parte, a TV linear e locadoras. Nesse contexto, os sistemas de recomendação são um diferencial fundamental dessas plataformas, utilizando algoritmos avançados para personalizar a experiência do usuário.

Com isso, é necessário que as plataformas utilizem algoritmos eficazes para fazer a recomendação. Tendo em vista que há um volume massivo de conteúdo disponível, a recomendação proporciona uma experiência personalizada ao usuário, facilitando sua decisão do que assistir com base no perfil individual, além de aumentarem a probabilidade de o usuário permanecer na plataforma por mais tempo. Todas essas questões são fundamentais uma vez que é um mercado saturado e a competitividade entre as plataformas é altíssima.

2 Objetivos

O objetivo geral é analisar a eficácia de dois algoritmos de recomendação principais utilizados pelas plataformas de streaming, filtragem colaborativa baseada em usuário e filtragem baseada em conteúdo. Nesse sentido, o trabalho irá:

- Implementar e comparar algoritmos de filtragem colaborativa e baseada em conteúdo, utilizando um dataset que possui avaliações reais de filmes feitas por diversos usuários.
- Realizar uma análise estatística para determinar se há diferença significativa na performance dos dois tipos de algoritmos.
- Avaliar a precisão das recomendações geradas por cada algoritmo, utilizando métricas de avaliação como precisão, recall e F1-score.
- Identificar as limitações de cada abordagem.

Dessa forma, espera-se que seja possível verificar se os dois algoritmos de recomendação são de fato eficazes, dado a demanda da problemática apresentada.

3 Método de pesquisa

método de pesquisa empregado é descrito em detalhes

Não esqueça de ser bem detalhista em todos os processos utilizados para confecção do trabalho, além de descrever a metodologia de análise dos dados.

O presente trabalho realizou uma análise comparativa entre dois algoritmos de recomendação de filmes: filtragem colaborativa e filtragem baseada em conteúdo. O objetivo principal foi avaliar o desempenho desses algoritmos utilizando métricas como precisão, recall e F1-Score, aplicando métodos estatísticos para interpretar as diferenças observadas. A seguir, são descritos os processos empregados na coleta, preparação e análise dos dados.

3.1 Coleta de Dados

O conjunto de dados utilizado no projeto foi o MovieLens, amplamente reconhecido em pesquisas sobre sistemas de recomendação. Esse dataset contém informações sobre filmes, usuários e avaliações, proporcionando uma base sólida para o desenvolvimento e teste de algoritmos de recomendação. Para a análise, os dados foram divididos aleatoriamente em conjuntos de treino e teste, assegurando a validação cruzada dos modelos.

3.2 Pré-processamento

Com o objetivo de reduzir a complexidade computacional dos algoritmos, tanto em termos de tempo de processamento quanto de uso de memória, foi aplicado um filtro aleatório nos dados originais. Esse procedimento reduziu o tamanho do dataset, mantendo uma amostra representativa para treinamento e teste. Essa redução é crucial para garantir que os experimentos fossem viáveis dentro do contexto computacional disponível, sem comprometer a qualidade da análise.

3.3 Implementação dos Algoritmos

Foram implementados dois algoritmos de recomendação com características distintas:

1. Filtragem Colaborativa: Baseado na similaridade de cossenos entre as avaliações dos usuários, este método recomenda filmes que outros usuários com gostos semelhantes consideraram relevantes.
2. Filtragem por Conteúdo: Utilizou o modelo TF-IDF (Term Frequency-Inverse Document Frequency) para representar as características dos filmes. A similaridade de cossenos foi empregada para identificar conteúdos similares aos filmes previamente avaliados positivamente pelo usuário.

Ambos os algoritmos foram programados para processar entradas de avaliação no formato “usuário-filme-nota” e retornar uma lista ordenada de recomendações.

3.4 Teste dos Algoritmos

Para avaliar o desempenho dos algoritmos, foi desenvolvida uma função de teste que simula a interação de usuários com o sistema. Essa função segue as etapas abaixo:

1. Seleciona aleatoriamente n combinações de usuário-filme-avaliação como base para teste.
2. Cada algoritmo gera m recomendações de filmes para cada usuário.
3. A relevância de cada recomendação é avaliada segundo a seguinte regra: um filme y é considerado relevante se, para um usuário aleatório que avaliou positivamente o filme x , pelo menos outro usuário gostou de y .
4. Os resultados das recomendações (relevantes ou irrelevantes) são registrados para compor as matrizes de confusão de cada algoritmo.

3.5 Construção das Matrizes de Confusão

Com base nos resultados das recomendações, foram construídas matrizes de confusão para cada algoritmo, considerando as classificações como relevantes (positivas) ou irrelevantes (negativas).

3.6 Cálculo das Métricas de Desempenho

Com base nas matrizes de confusão, foram calculadas as métricas de precisão, recall e F1-Score para ambos os algoritmos:

- Precisão: Mede a proporção de recomendações relevantes entre todas as recomendações feitas.
- Recall: Mede a proporção de itens relevantes corretamente recomendados.
- F1-Score: Combina precisão e recall em uma métrica harmônica que reflete o equilíbrio entre as duas.

Os valores foram armazenados e utilizados na análise comparativa para avaliar a eficácia de cada abordagem.

3.7 Visualização dos resultados

Para facilitar a interpretação dos resultados, foi gerado um gráfico de barras comparando as métricas de precisão, recall e F1-Score entre os algoritmos. Esse gráfico permitiu uma visualização clara das diferenças de desempenho, evidenciando os pontos fortes e as limitações de cada abordagem.

4 Resultados e Análises


são apresentados os testes e resultados obtidos a partir da implementação do método proposto, especifica-se a plataforma de testes e discutem-se os resultados.

na hora de colocar as imagens ver as especificações certinho que ela colocou no template

Os algoritmos foram avaliados utilizando n interações simuladas de recomendações, com m recomendações por interação. As matrizes de confusão de ambos os métodos forneceram os dados necessários para calcular as métricas de desempenho: precisão, recall e F1-Score. Os valores obtidos foram os seguintes:


5 Matrizes de Confusão

Figura 1 - Matriz de Confusão de Filtragem Colaborativa



Fonte: Autoral

Figura 2 - Matriz de Confusão de Filtragem Baseada em Conteúdo



Fonte: Autoral

Filtragem colaborativa:

- Precisão: 34
- Recall: 99,8
- F1-Score: 51

Filtragem por conteúdo:

- Precisão: 78
- Recall: 99,9
- F1-Score: 82


A filtragem colaborativa apresentou alto recall, indicando que é eficiente para recuperar a maioria dos itens relevantes. No entanto, o baixo valor de precisão reflete uma alta taxa de falsos positivos, ou seja, muitos itens recomendados não eram relevantes para o usuário. Isso impacta negativamente a experiência, pois o usuário é sobrecarregado com recomendações de baixa qualidade.

Por outro lado, a filtragem baseada em conteúdo alcançou um desempenho superior em todas as métricas. O F1-Score de 0.82 indica um equilíbrio mais adequado entre precisão e recall, tornando o algoritmo mais confiável para aplicações práticas. Esse resultado reflete a capacidade do método de recomendar itens alinhados às preferências específicas dos usuários com maior assertividade.

Os resultados sugerem que, embora ambos os métodos possam ser eficazes dependendo do contexto, a filtragem por conteúdo é mais adequada em sistemas onde a precisão das recomendações é crítica. Por outro lado, a filtragem colaborativa pode ser útil para aumentar a diversidade das sugestões, apesar de sua menor precisão.

Para facilitar a interpretação, foi gerado um gráfico de barras comparando as métricas de desempenho dos dois algoritmos. A visualização destaca as diferenças entre as abordagens, evidenciando o equilíbrio superior do método de filtragem por conteúdo.

Figura 3 - Gráfico de Comparação de Métricas



Fonte: Autoral

6 Conclusão

Em síntese, ambos os algoritmos apresentam vantagens e desvantagens, contudo, os resultados evidenciam uma maior eficácia do algoritmo baseado em conteúdos. Este apresenta métricas expressivas, com uma precisão de 99,98%, acurácia de 70,23%, sensibilidade de 69,99% e especificidade de 98,54%. Apesar desses indicadores positivos, é importante ressaltar que o

algoritmo ainda necessita de melhorias, uma vez que a acurácia, embora superior à do algoritmo colaborativo, permanece insuficiente para aplicações em larga escala, como as demandadas por grandes empresas.

O algoritmo colaborativo, por sua vez, demonstra números menos competitivos em relação ao baseado em conteúdos. Suas métricas incluem uma acurácia de 36,42%, precisão de 99,88%, sensibilidade de 34,58% e especificidade de 98,57%. Estes resultados revelam que, embora o modelo tenha elevado desempenho na identificação de itens verdadeiramente relevantes (alta precisão), ele apresenta significativa limitação ao permitir que muitos itens irrelevantes sejam recomendados simultaneamente, comprometendo, assim, a eficácia geral da recomendação.

Para aprimorar ambos os algoritmos, algumas estratégias podem ser implementadas. Uma das abordagens seria o aumento do limiar (*threshold*) de decisão, ampliando a quantidade de informações utilizadas para a recomendação. No caso do algoritmo colaborativo, isso poderia ser alcançado com um aumento no número de usuários disponíveis para a geração das recomendações, enriquecendo o conjunto de dados e, conseqüentemente, melhorando a precisão do modelo. Já para o algoritmo baseado em conteúdos, uma alternativa seria incorporar novos parâmetros ao treinamento, como categorias de filmes, diretores, elenco, avaliações críticas e outras métricas relevantes. Essa ampliação no conjunto de atributos pode tornar o modelo mais robusto e detalhado, garantindo maior assertividade nas recomendações.

Dessa forma, embora ambos os algoritmos tenham desempenho aceitável em certos contextos, a aplicação prática requer melhorias significativas para atender aos padrões de qualidade esperados em cenários de grande escala. O investimento em dados mais ricos e estratégias de modelagem avançadas representa um caminho promissor para alcançar melhores resultados.

Referências

- [1] Burke, R. **Hybrid recommender systems: Survey and experiments.** *User Modeling and User-Adapted Interaction*, 2002.
- [2] Linden, G., Smith, B., & York, J. **Amazon.com recommendations: Item-to-item collaborative filtering.** *IEEE Internet Computing*, 2000.
- [3] <https://grouplens.org/datasets/movielens>