

Definição do Analisador Léxico

1. Alfabeto e noções gerais

O alfabeto base considerado é composto pelos caracteres ASCII visíveis (com exceção das letras maiúsculas), acrescidos das quebras de linha nos formatos usuais dos sistemas operacionais: `\n` (Unix/Linux), `\r\n` (Windows) e `\r` (MacOS clássico).

O princípio de reconhecimento adotado segue a regra do casamento mais longo (maximal munch). Em casos de empate, a decisão é feita pela ordem das regras especificadas no arquivo de padrões. Toda cadeia de caracteres que não corresponder a nenhum padrão definido será considerada um erro léxico.

2. Classes léxicas (tokens)

2.1 Comentários

Padrão: `~([^\n])*\n~`

Descrição: cadeias iniciadas por `~`, seguidas de zero ou mais caracteres diferentes de `~` (incluindo quebras de linha), e encerradas por outro `~`.

Exemplos válidos: `~comentário~`, `~bloco\nmultilinha~`, `~~` (comentário vazio).

2.2 Identificadores e palavras reservadas

Identificadores comuns (VAR): `[a-z][a-z0-9]+`

Exemplos válidos: `v1`, `abc123`. Não aceitos: `_x`, `A`, `a-1`.

Identificadores de função (FUNC): `FB[a-z]+`. Exemplos válidos: `FBfoo`, `FBbar`. Não aceitos: `Fbfoo`, `FB1`.

Palavra reservada (RETURN): `"return"`. Deve vir antes da regra de VAR para não ser interpretada como identificador.

2.3 Literais

Números inteiros (LONG): `[0-9]+`. Exemplos: `0`, `12345`.

Números de ponto flutuante (LONGLONG): `[0-9]+\.[0-9]+`. Exemplos: `0.0`, `12.34`.

Strings (PAPO): `"([^\n\\])"`. Exemplos: `"ola"`, `"texto \ com aspas"`, `"bar\n"`.

2.4 Operadores

`+` → MAIS, `-` → MENOS, `*` → MULT, `/` → DIV, `==` → EQUALS, `<` → MENOR, `>` → MAIOR, `<=` → ATRIBUIÇÃO.

2.5 Pontuação e delimitadores

`,` → VIRG, `.` → PT, `;` → PTVIRG, `( )` → ABREPAR/FECHAPAR, `{ }` → ABRECH/FECHACH, `[ ]` → ABRECOL/FECHACOL.

2.6 Quebras de linha

Padrão: `(\r\n|\r|\n)`. Usado para atualizar a numeração de linhas e/ou emitir tokens de nova linha.

2.7 Símbolos auxiliares

LETTER = `[a-z]`, DIGIT = `[0-9]`, ESCAPE = `\\`.

3. Observações gerais e limitações

- Reconhecimento é case-sensitive.

- Não há suporte a Unicode/acentos.
- Literais numéricos não contemplam sinal opcional nem notação científica.
- Strings não permitem quebras de linha e apenas escapes simples.
- Comentários ~...~ não suportam aninhamento.

4. Exemplos de cadeias reconhecidas

Pertencentes:

v1, abc123, FBfoo, return, 123, 45.67, "ola", "aspas \" internas\"", ~comentário em bloco~, x <- 1;, f <- 2, ==, (, .

Não pertencentes:

A, _x, 12., .5, "string\nquebra", ~sem fechamento