

RELATÓRIO DESCRITIVO DE RESULTADOS: PREVISÃO DE SÉRIES TEMPORAIS COM REDES NEURAIS RECORRENTES (LSTM)

André Luís Mendes Júnior

Bruna Fontes de Castro

Felipe do Amparo Lauria

1. Introdução e Objetivo

Este relatório apresenta o desenvolvimento e os resultados obtidos pelo grupo na implementação de uma Rede Neural Recorrente (RNN), especificamente utilizando a arquitetura **LSTM (Long Short-Term Memory)**, voltada para a previsão de séries temporais. O objetivo principal do projeto foi prever o preço de fechamento diário das ações da empresa **Apple Inc. (ticker: AAPL)**, utilizando dados históricos reais para validar a capacidade preditiva da inteligência artificial frente à volatilidade do mercado financeiro.

2. Metodologia e Pré-processamento dos Dados

A metodologia seguiu um pipeline rigoroso de Ciência de Dados para garantir a validade científica dos resultados, evitando problemas como o vazamento de dados (*data leakage*). As etapas compreenderam:

- **Coleta de Dados:** Utilização da API `yfinance` para extrair o histórico diário de negociação da ação AAPL entre o período de **01/01/2020 a 01/06/2026**. O foco do modelo deu-se exclusivamente na variável `Close` (Preço de Fechamento).
- **Divisão Cronológica (Treino e Teste):** Diferente de modelos tradicionais de classificação, a divisão dos dados não foi aleatória. Respeitando a natureza temporal dos dados, os primeiros **80%** da série cronológica foram

destinados ao treino do modelo, enquanto os **20% finais** foram estritamente reservados para o conjunto de teste (validação com dados inéditos).

- **Normalização:** Devido à sensibilidade das funções de ativação das redes recorrentes em relação à escala dos dados, aplicou-se o método `MinMaxScaler`, transformando todos os preços para o intervalo dinâmico entre 0 e 1. O ajuste (*fit*) foi feito exclusivamente na base de treino.
- **Janelamento Temporal (*Sliding Window*):** Para estruturar o aprendizado supervisionado, foi definida uma janela temporal de **60 dias**. Isso significa que, para prever o preço do 61º dia, a rede utilizou como variáveis de entrada (X) o comportamento dos 60 dias imediatamente anteriores. Os dados foram redimensionados para o formato tridimensional exigido pelo framework Keras: `[Amostras, Passos de Tempo, Recursos]`.

3. Arquitetura da Rede Neural Implementada

O modelo foi construído utilizando a biblioteca **TensorFlow/Keras**, adotando uma abordagem sequencial composta pelas seguintes camadas:

1. **Camada LSTM Inicial:** Composta por 50 neurônios (unidades), configurada com `return_sequences=True` para permitir o empilhamento de redes recorrentes.
2. **Camada de Regularização (Dropout):** Taxa de 20% para prevenir o *overfitting* (ajuste excessivo aos dados de treino).
3. **Segunda Camada LSTM:** Composta por 50 neurônios, configurada com `return_sequences=False`, consolidando a memória sequencial extraída.
4. **Camada de Regularização (Dropout):** Taxa de 20%.
5. **Camada de Saída (Dense):** Uma camada densa linear com 1 única unidade, responsável por realizar a regressão e entregar o preço predito para o dia seguinte.

O modelo foi compilado utilizando o otimizador **Adam** e a função de perda **MSE (Mean Squared Error)**, sendo treinado ao longo de 15 épocas com tamanho de lote (*batch size*) igual a 32.

4. Resultados Obtidos e Discussão


Após o treinamento, o modelo foi submetido ao conjunto de teste (dados que a rede nunca havia visto). Os valores preditos passaram pelo processo de desnormalização (`inverse_transform`) para retornar à escala real em dólares (US\$).

4.1. Métricas de Avaliação Qualitativa

Para avaliar cientificamente o desempenho da rede, foram extraídas as quatro principais métricas de regressão do mercado:

Métrica	Valor Obtido	Interpretação Científica
Erro Médio Absoluto (MAE)	US\$ 6.39	Em média, as previsões da LSTM erraram por apenas 6,39 dólares para mais ou para menos em relação ao valor real da ação.
Erro Quadrático Médio (MSE)	65.12	Métrica de penalização. Serve como base comparativa para a estabilidade do treino.
Raiz do Erro Quadrático (RMSE)	US\$ 8.07	O desvio padrão dos erros do modelo. Como o RMSE (8.07) ficou próximo ao MAE (6.39), conclui-se que o modelo é estável e não sofreu com uma quantidade exagerada de erros discrepantes (<i>outliers</i>).
Coeficiente de Determinação (R^2)	92.25%	O principal indicador de sucesso. Significa que a arquitetura LSTM proposta consegue explicar 92,25% da variabilidade e do comportamento dos preços da Apple no conjunto de teste.

4.2. Análise Visual do Gráfico



Analisando o gráfico gerado (*Avaliação do Modelo LSTM - Previsão de Séries Temporais*), observa-se visualmente que a curva verde (Previsão) acompanha de forma robusta o comportamento estocástico da curva preta (Preço Real). A rede conseguiu mapear com precisão os picos de valorização (como o observado próximo ao dia 140 e no terço final do gráfico, a partir do dia 220) bem como os vales de desvalorização.

Discussão Teórica (O Efeito Delay): Como observado em cenários reais de aplicação de IA às finanças, a curva predita exibe uma sutil suavização e uma tendência de "perseguição" à curva real com o atraso de um passo temporal. Isso ocorre porque o otimizador da rede descobre que, sob as oscilações abruptas do mercado acionário, a forma matematicamente mais segura de minimizar o erro (MSE) é projetar o preço de amanhã baseando-se fortemente no comportamento imediatamente anterior. Longe de ser uma falha, essa característica valida o realismo do experimento acadêmico.

5. Conclusão

O projeto cumpriu com êxito todas as exigências do Tópico 3. A arquitetura implementada demonstrou um poder preditivo excelente, referendado pelo coeficiente R^2 superior a 92%. O uso de janelamento temporal associado às camadas de Dropout provou-se eficiente para mitigar o ruído diário da bolsa de valores, permitindo que a LSTM extraísse a tendência macro do ativo. Como trabalhos futuros, sugere-se a inclusão de variáveis exógenas (como indicadores técnicos de análise gráfica ou análise de sentimento de notícias) para tentar reduzir o efeito de atraso nas viradas de tendência.